

Teoría 4- diseño de algoritmos paralelos

miércoles, 9 de abril de 2025 10:57

Pasos generales a realizar:

- Identificar porciones de trabajo (tareas) que puedan resolverse en paralelo
- Asignar tareas a procesos que se ejecutan en diferentes procesadores
- Distribuir datos de entrada, de salida e intermedios asociados con el programa
- Administrar accesos a datos compartidos
- Sincronizar procesos en diferentes etapas del programa

Descomposición en tareas:

Dividir el cómputo en partes más chicas \rightarrow a más tareas pequeñas más flexibilidad

Una primera aproximación consiste en pensar tareas de igual código (paralelismo de datos o de dominio) o tareas de código diferente (paralelismo funcional)

Descomposición de datos:

descomponer los datos asociados a un problema en pequeñas porciones (usualmente del mismo tamaño) y luego asociarle el cómputo relacionado a las mismas para generar las tareas.

Descomposición funcional:

Se enfoca en el cómputo a realizar divide el cómputo en tareas disjuntas y después ve los datos.

Lo ideal es que no necesiten los mismos datos, pero si si pasa hay que tener cuidado y comunicarlos para no cagarla

Enfocarse en el cómputo a realizar facilita la estructuración del programa y el descubrimiento de oportunidades de optimización (situación no tan obvia cuando uno se enfoca en los datos)

Descomposición de tareas:

Caso ideal: tareas full independientes, todas se pueden computar a la vez.

Se puede usar grafo de dependencias para saber el orden

Grado de concurrencia:

Cantidad de tareas que se ejecutan en paralelo


El nro varia durante la ejecución, lo que nos interesa es el promedio o el máximo

El camino crítico determina el promedio. Es el camino dirigido más largo entre un nodo inicial y uno final.

La suma de los pesos de los nodos es la longitud del camin crítico


$\text{Grado de concurrencia promedio} = \text{Peso total} / \text{Longitud del camino crítico}$

Camino critico corto \rightarrow mayor grado de concurrencia \rightarrow



(a)

$$GCP = \frac{63}{27} = 2.33$$



(b)

$$GCP = \frac{64}{34} = 1.88$$

Del análisis anterior, podría parecer que el tiempo de ejecución paralela se puede reducir indefinidamente al lograr una descomposición que sea cada vez más fina (más tareas de menor tamaño) < esto no es lo usual. En general, hay un límite inherente al problema sobre qué tan fina puede ser una descomposición. Por ejemplo, el producto matriz-vector no admite más de n^2 tareas concurrentes. Además se debe tener en cuenta que las tareas deben comunicarse y sincronizar < esto significa overhead que limita el speedup alcanzable. Un adecuado balance entre cómputo y comunicación definirá el rendimiento alcanzable.

No me queda claro

Aglomeración de tareas:

Ver si conviene combinar tareas para tener menos tareas pero más grande. El nro de tareas debería ser igual a la cantidad de núcleos de proces a usar

- Aumentar la granularidad: elimina la necesidad de comunicar datos entre ellas al combinarlas
- Mantenimiento de la flexibilidad: al combinar tareas se limita la escalabilidad del algoritmo. Si puede crear un nro variables de tareas, entonces tiene más portabilidad y escalabilidad.
- Menos costo de desarrollo

Cómo descompongo en tareas?

Técnica recursiva:

Bueno para los problemas divide y vencerás.

Dividis en subproblemas independientes. Después seguís dividiendo recursivamente hasta conseguir cierta granularidad.

A veces se pueden combinar resultados parciales.

A veces hay que recomputar el cómputo para que se pueda usar

Técnica basada en los datos:

Bueno para cuando se opera sobre grandes estructuras de datos.

Se particionan los datos a procesar

Se usa la partición para inducir una descomposición del cómputo en tareas

Varias formas:

- Basada en los datos de salida:
 - Se usa cuando cada elemento de salida se puede calcular independientemente como función de los datos de entrada. Ej. mult. de matrices

- A cada tarea se le asigna el cómputo relacionado a una porción de la entrada
- **Basada en datos de entrada**
 - No siempre se puede por salida. Ej cuando se buscan mínimos o máximos en una lista o Cuando se ordena un vector
 - A cada tarea se le asigna una porción de los datos de entrada y hace todo los cómputos relacionados a la misma. A veces se hace reducción de salidas parciales
 - Ej: contar ocurrencias en un vector, buscar elementos, etc.
- **Basada en datos intermedios**
 - Hay veces que la salida de una etapa es la entrada de la siguiente
 - Entonces se descomponen los datos de una etapa intermedia
 - (no entendí x)
- **Exploratoria:**
 - desarrollar algunos niveles desde la configuración inicial en forma secuencial. Luego, cada nodo es asignado a una tarea para realizar la búsqueda en forma concurrente. Cuando una la encuentra, le avisa al resto.
- **Especulativa:**
 - Se usa cuando hay varios caminos distintos que puede tomar el programa.
 - Es como un case que se evalúan todas las opciones al mismo tiempo. Cuando la entrada del case está disponible, se descartan las que no y sigue.
 - En especulativa, la entrada de una bifurcación que lleva a múltiples nuevas tareas es desconocida. En cambio con exploratoria, la salida de las múltiples tareas que salen de una bifurcación son desconocidas.
- **Híbrida:**
 - combinación de las anteriores

Etapas de mapeo de tareas a procesos: