








Inteligencia Artificial



Inteligencia Artificial: Definiciones



Inteligencia Artificial: Definiciones

Inteligencia = Difícil
Múltiples definiciones





Artificial = Fácil
Hecho por humanos




Inteligencia: Definiciones

- Definiciones de Inteligencia:
 - Habilidad para **tomar** y mantener determinada **dirección**, **adaptarse** a nuevas situaciones y tener la capacidad para **criticar** los propios actos (Francois Binet, 1900)
 - La inteligencia es un **término genérico** para designar al **conjunto** de **operaciones lógicas** para las que está capacitado el ser humano, yendo desde la percepción, las operaciones de clasificación, sustitución, abstracción, etc. hasta -por lo menos- el cálculo proporcional (Piaget, 1950)
 - Medida de la **eficiencia** en **adquirir habilidades** en un ámbito de tareas, con respecto a conocimientos previos, experiencia y dificultad de generalización ([Francois Chollet](#), 2019)
- ¿Son verificables?
- ¿Admiten inteligencias no humanas?




Inteligencia: Definiciones

- Definiciones de Inteligencia **Verificables**
 - **Test de Turing:** comportarse de forma indistinguible a un ser humano. Centrada en humanos
 - Ej: Mantener una conversación
 - **Éxito en tareas:** Habilidad para resolver una tarea X, tal que existe una métrica de éxito $E(X)$
 - Ej: Detectar un rostro en una imagen
 - Ej: Ladrar cuando al percibir algo fuera de lo común



Inteligencia: Definiciones

- Inteligencia **humana**
 - Habilidad de **actuar** como **persona humana**
- Inteligencia **no humana**
 - Habilidad de resolver **tareas** que no son:
 - **Resolubles** por personas
 - Ej: Realizar cálculos con miles de millones de datos
 - **Relevantes** para las personas
 - Ej: Ladrar cuando al percibir algo fuera de lo común




Inteligencia: Definiciones

- Inteligencia **acotada o débil**
 - Habilidad de resolver una sola tarea particular
 - Ejemplos:
 - Multiplicar una matriz
 - Encontrar caras en una foto
 - Jugar al ajedrez
 - No generaliza a otras tareas
 - Inteligencia **general o fuerte**
 - Robusta, flexible, general, adaptable
 - Objetivo tradicional de la IA
 - No existe actualmente




Inteligencia Artificial: Definiciones

- **Inflación** del término
 - Cuando una tarea se “resuelve”, deja de considerarse inteligencia artificial
- Definición por **contraposición**
 - La **IA** está compuesta por todas las **tareas que** todavía **NO** podemos **resolver** con una **computadora**
- Ejemplos:
 - Ajedrez: símbolo de la inteligencia humana
 - “Resuelto” en 1997
 - No requirió *inteligencia general*



Super-Inteligencia: Definiciones

- Superinteligencia
 - Inteligencia que **supera radicalmente** las mentes **humanas** más brillantes en todos los campos, incluyendo la creatividad científica, la sabiduría general y las habilidades sociales. Bostrom 2017.
- Por ahora, ciencia ficción



Tipos de inteligencia artificial


Inteligencia Artificial

Simbólica

Sistemas
basados en
agentes

Sistemas
basados en
reglas

Conocimiento
Experto y
Simulación




No Simbólica

Aprendizaje
Automático



Minería de
datos

Datos









Paradigma principal


Inteligencia Artificial y campos relacionados



Nombres y blabla



Inteligencia Artificial basada en Datos (Machine Learning)




Datos



1	2	3	C
0,5	0,8	0,1	0,1
0,6	0,2	0,4	0,9
0,6	0,7	0,3	0,2
0,2	0,1	0,2	0,3
0,6	0,5	0,9	0,3


Preprocesamiento +
Representación



Entrenamiento



Genera



Modelo



Evaluar

Datos que no
conoce el
modelo




80% del costo del
proyecto




Redes Neuronales de varias capas (Deep Learning)

Machine Learning



Deep Learning





Ejemplo de Aprendizaje Automático Tradicional


Detección de Peatones



Entrada



Características HOG
(~10 años de inv.)




Modelo simple

Ejemplo de Redes Neuronales

Detección de Peatones



Entrada



Factores clave para desarrollo de Deep Learning

- Crecimiento exponencial desde 2010
 - Teoría base existe hace décadas!
- Aumento en cantidad y calidad de datos
 - imágenes, texto, audio, etc.
- Nuevo hardware específico (GPU/TPU)
 - Aumento de poder de cómputo 10-20x



Problemas con Deep Learning

Modelos Interpretables
(Caja blanca)



Fácil interpretar el modelo:

- Modelos más simples
- Más conocimiento experto
- Ej: Regresión lineal

Modelos No Interpretables
(Caja negra)



Difícil interpretar el el modelo:


- Modelos más complicados
- Menos conocimiento experto
- Ej: Redes Neuronales

Machine Learning e IA (en el 2019)



AI Publications in All Publications


Source: Scopus, 2019.



<https://towardsdatascience.com/democratizing-artificial-intelligence-42222472d3d4>

https://hai.stanford.edu/sites/g/files/sbiybj10986/f/ai_index_2019_report.pdf


Machine Learning e IA (en el 2019)



Number of AI papers on arXiv, 2010-2019

Source: arXiv, 2019.

Publicaciones en IA




Tensorflow y otros frameworks (en el 2019)




Cumulative GitHub stars by AI library (2015—2019)

Source: Github, 2019.



Idem pero sin
TensorFlow




Trabajos en IA (en el 2019)




Share of Total Online Job Postings, USA, 2010-2019 monthly

Source: BurningGlass, 2019.

Puestos de trabajo



Autoría de artículos (en el 2019)




Ética e IA (en el 2019)



Number of paper titles at AI conferences mentioning Ethics keywords, 1969-2018

Source: Prates et al., 2019.

Ética en IA



Ética e Inteligencia Artificial

Inteligencia artificial en el mundo

Reconocimiento del habla

Vehículos autónomos

Asistentes virtuales

Filtros de Spam

Autocompletado de texto

Industria y robótica

Identificación de rostros

Generación de arte

Ciencia

Búsqueda inteligente

Ruteo y planeamiento


Sistemas de recomendación

Análisis de señales

Reconocimiento de caracteres

Comercio automatizado


Marketing y publicidad



Sistema de IA global (jerárquico)



Personas
Culturas
Sociedades




Instituciones
Estados
Empresas



Sistemas (con y sin IA)

Inteligencia artificial y software

- Software
 - Colección de funciones
 - Forman un programa
- Inteligencia artificial
 - Función **especial** dentro de un programa
 - **Difícil** caracterizar
 - Ejemplos
 - Jugar al Ta-Te-Ti
 - $\text{tateti}(\text{Estado}) \rightarrow \text{Acción}$
 - Manejar un auto automáticamente
 - $\text{manejar}(\text{Estado}) \rightarrow \text{Acción}$



Modelos de IA basados en *datos*

- Modelos que *aprenden* o se *entrenan*
- Datos → Ejemplos



Ejemplos




Algoritmo de
Aprendizaje



Modelo

Inteligencia artificial: cambio de paradigma

- 1950 - 2010: Sistemas de **IA custom**
 - Basados en conocimiento experto
 - Lógica y búsqueda
- 2010 - Hoy: Sistemas de **IA como APIs**
 - Modelos basados en **datos masivos**
 - Crecimiento de información disponible
 - Modelos conexionistas o no simbólicos
 - Redes Neuronales o Deep Learning
 - Aumento del poder de cómputo
 - GPUs, TPUs, dispositivos especiales



Impacto de sistemas de AI: Ejemplo de GPT

- GPT: Modelo de generación de texto
- Dada una entrada, completa la salida. Ejemplos:
 - Entrada: *Te hacías un café con azúcar, pero no tenías cuchara así que revolvíste con una lapicera. Resulta que fue una mala idea porque ...*
 - Salida: **la lapicera se derritió.**
- Alta calidad, posibilita nuevas aplicaciones
 - Chatbots, asistencia para escribir/programar, etc
 - Generar Spam o contenido falso
 - Requiere análisis de impacto
 - Release Strategies and the Social Impacts of Language Models

Aspectos a evaluar

- **Desempeño**

- ¿El modelo realiza la tarea correctamente?

- **Interpretabilidad**

- ¿Cómo afecta a la salida un cambio en la entrada?
- ¿Se pueden comprender los pasos para generar la salida?
 - Caja blanca vs Caja Negra


- **Sesgo de datos**

- Datos usados para generar un modelo
 - ¿reflejan la realidad? ¿deben reflejarla? ¿la de quienes?

- **Interacción con el mundo real**

- ¿Cómo afectará el sistema al mundo real?

Agregar o modificar sistemas de IA



Considerar el impacto

Problemáticas asociadas a modelos de IA

- Estás desarrollando alguno de estos sistemas
 - a. Reconocedor de habla para celulares/computadoras.
 - b. Generador de imágenes artísticas para un software de diseño.
 - c. Predictor del crecimiento económico de un país para evaluación de riesgos financieros.
- ¿Qué impactos podés preveer a largo plazo si el sistema es exitoso?
- ¿Qué medidas podés tomar para mitigar los impactos negativos?

Minería de Datos



Minería de Datos



Datos



Conocimiento
Información
Conclusiones

Varias perspectivas sobre el proceso


Minería de datos vs Ciencia de datos

- Marketing de nombres
- Diferencias mínimas
- Otros:
 - Data Engineering
 - Data Analytics
 - Information Retrieval



Minería de datos vs otros campos

- En la práctica, no hay diferencias claras
- Enfocarse en técnicas y no en campos




Minería de Datos vs Estadística

Minería de Datos	Estadística
Exploratoria	Confirmatoria
Inductiva	Deductiva
Muchas variables	Pocas variables
Muchos datos	Pocos datos
Datos numéricos y no numéricos	Datos numéricos
Pocas asunciones	Muchas asunciones
Pocas garantías	Muchas garantías

Enfoque Confirmativo vs Exploratorio

Confirmativo




Exploratorio




Metodologías en Minería de Datos


- Visiones complementarias



EDA: Exploratory Data Analysis (1977, John Tukey)
Estadística con énfasis en Datos



KDD: Knowledge Discovery in Databases (1989, KDDSIG)



CRISP-DM: Cross Industry Standard Process for Data Mining (1999, EU)

Knowledge Discovery in Databases (KDD, 1989)

- Minería de datos = etapa de KDD

Datos: 80% del esfuerzo



Obtención

Selección y
Limpieza

Preprocesamiento
y transformación (Minería de datos)


Modelado

Conocimiento

Proceso iterativo

CRISP-DM: Cross Industry Standard Process (1996)

- Minería de datos = todo el proceso



Definición del Problema Exploración de datos Preparación de datos Modelado Evaluación Despliegue

Proceso iterativo

Exploratory Data Analysis (1977, Tukey)

- Metodología sólo para fases de datos
- Aplicar en KDD o CRISP o estadística común



Definición del
Problema

Exploración
de datos

Preparación de
datos

Modelado

Evaluación

Despliegue



- Visualizar y transformar los datos sin hipótesis previas
- Inspiro a los lenguajes S y luego R (R for Data Science)

Datos

The background features a dark blue gradient with dynamic, glowing trails of blue and white particles. These particles form a large, sweeping arc that starts from the bottom left and curves towards the top right, creating a sense of motion and data flow. A thin, horizontal green line is positioned across the middle of the image, just below the word 'Datos'.


Fuentes de datos¹



Geolocalización




Procesos Industriales



Sitios Web




Bases de datos



Uso de Dispositivos



Redes Sociales




Sensores



Tráfico en Redes

Volúmen de datos



Entran en RAM

- Hasta 64/128gb
- Mayoría de bases de datos



Pueden almacenarse

- 10 TB = 10^{13} B: Un servidor casero
- 100 TB = 10^{14} B: Servidor de empresa
- 100 PB = 10^{17} B: Large Hadron Collider (LHC)
- 40 ZB = $40 \cdot 10^{21}$ B: Almacenamiento total disponible en la tierra en 2020. 90% entre 2018 y 2020
- 200 ZB = Proyectado para 2025


No pueden almacenarse

- 1.7mb/persona/seg



Tipos de Datos


Grafos




Bases de datos



Series
Temporales



Audio



Texto



Imágenes y video

Datos Tabulares






Datos Tabulares (o *rectangulares*)

- Filas = Ejemplos
- Columnas = Atributos o Variables o Características o *~Features*
- Celdas = Valores
- Un solo archivo
 - Formatos comunes:



	nombre	posiciones	edad	altura	peso	pie preferido
1	Lionel ...	RW, CF, ST	32	170	72	Izquierdo
2	Cristiano ...	ST, LW	34	187	83	Derecho
3	Neymar da ...	LW, CAM	27	175	68	Derecho
4	Eden Hazard	LW, CF	28	175	74	Derecho
5	Kevin De ...	CAM, CM	28	181	70	Derecho
6	Virgil van ...	CB	27	193	92	Derecho
7	Luka Modrić	CM	33	172	66	Derecho
8	Mohamed ...	RW, ST	27	175	71	Izquierdo
9	Kylian ...	ST, RW	20	178	73	Derecho
10	Kalidou ...	CB	28	187	89	Derecho
11	Harry Kane	ST	25	188	89	Derecho
12	N'Golo Kanté	CDM, CM	28	168	72	Derecho
13	Giorgio ...	CB	34	187	85	Izquierdo
14	Sergio ...	ST	31	173	70	Derecho
15	Sergio ...	CB	33	184	82	Derecho
16	Luis Albert...	ST	32	182	86	Derecho
17	Robert ...	ST	30	184	80	Derecho
18	Sergio ...	CDM, CM	30	189	76	Derecho
19	Antoine ...	CF, ST, LW	28	176	73	Izquierdo

Tipos de Atributos



Tipos de Atributos

- **Nombre:** Nominal
- **Posiciones:** ¿Nominal?
- **Edad:** Discreto
- **Altura:** Discreto
 - Si lo codificamos en m?
- **Peso:** Discreto
 - Si lo codificamos como Bajo/Medio/Alto?
- **Pie Preferido:** Nominal

	nombre	posiciones	edad	altura	peso	pie preferido
1	Lionel ...	RW, CF, ST	32	170	72	Izquierdo
2	Cristiano ...	ST, LW	34	187	83	Derecho
3	Neymar da ...	LW, CAM	27	175	68	Derecho
4	Eden Hazard	LW, CF	28	175	74	Derecho
5	Kevin De ...	CAM, CM	28	181	70	Derecho
6	Virgil van ...	CB	27	193	92	Derecho
7	Luka Modrić	CM	33	172	66	Derecho
8	Mohamed ...	RW, ST	27	175	71	Izquierdo
9	Kylian ...	ST, RW	20	178	73	Derecho
10	Kalidou ...	CB	28	187	89	Derecho
11	Harry Kane	ST	25	188	89	Derecho
12	N'Golo Kanté	CDM, CM	28	168	72	Derecho
13	Giorgio ...	CB	34	187	85	Izquierdo
14	Sergio ...	ST	31	173	70	Derecho
15	Sergio ...	CB	33	184	82	Derecho
16	Luis Albert...	ST	32	182	86	Derecho
17	Robert ...	ST	30	184	80	Derecho
18	Sergio ...	CDM, CM	30	189	76	Derecho
19	Antoine ...	CF, ST, LW	28	176	73	Izquierdo

Atributos Binarios

- Toman valores entre 0 y 1

- Ej: Pie preferido

- Crear atributos
 - *Pie izquierdo*

- *Pie derecho*

- Valen 1 o 0 dependiendo del valor de *pie preferido*

nombre	edad	altura	peso	posiciones	pie preferido	Derecho	Izquierdo
Lionel Andrés Messi Cuccittini	32	170	72	RW, CF, ST	Izquierdo	0	1
Cristiano Ronaldo dos Santos Aveiro	34	187	83	ST, LW	Derecho	1	0
Neymar da Silva Santos Junior	27	175	68	LW, CAM	Derecho	1	0
Eden Hazard	28	175	74	LW, CF	Derecho	1	0
Kevin De Bruyne	28	181	70	CAM, CM	Derecho	1	0
Virgil van Dijk	27	193	92	CB	Derecho	1	0
Luka Modrić	33	172	66	CM	Derecho	1	0
Mohamed Salah Ghaly	27	175	71	RW, ST	Izquierdo	0	1
Kylian Mbappé	20	178	73	ST, RW	Derecho	1	0
Kalidou Koulibaly	28	187	89	CB	Derecho	1	0
Harry Kane	25	188	89	ST	Derecho	1	0
N'Golo Kanté	28	168	72	CDM, CM	Derecho	1	0
Giorgio Chiellini	34	187	85	CB	Izquierdo	0	1
Sergio Leonel Agüero del Castillo	31	173	70	ST	Derecho	1	0
Sergio Ramos García	33	184	82	CB	Derecho	1	0
Luis Alberto Suárez Díaz	32	182	86	ST	Derecho	1	0
Robert Lewandowski	30	184	80	ST	Derecho	1	0
Sergio Busquets i Burgos	30	189	76	CDM, CM	Derecho	1	0
Antoine Griezmann	28	176	73	CF, ST, LW	Izquierdo	0	1
Paulo Bruno Exequiel Dybala	25	177	75	CAM, RW	Izquierdo	0	1

Modelos de Aprendizaje Automático



Tipos de Modelos

Modelo


Predictivo

- Generar o *entrenar* un modelo de **un atributo** en base a datos
- Nuevos datos **sin atributo**
 - Predecir **atributo**



Descriptivo

- Generar o *entrenar* un modelo de **todos los atributos** en base a datos
- El modelo es el resultado
 - Describe los datos



Tipos de Modelos

Modelo

Supervisado

- Generar o *entrenar* un modelo de **un atributo** en base a datos
- Nuevos datos **sin atributo**
 - Predecir atributo
- **Aprendizaje Supervisado**
 - Los datos originales contienen el atributo
 - Se puede **supervisar** el desempeño del modelo
- Supervisado $\subseteq$ Predictivo

No supervisado

- Generar o *entrenar* un modelo de **todos los atributos** en base a datos
- El modelo es el resultado
 - Describe los datos
- **Aprendizaje No Supervisado**
 - No hay una tarea concreta para supervisar
- No Supervisado $\subseteq$ Descriptivo

Terminología de Aprendizaje Automático

Aprendizaje Automático vs Minería de Datos

Aprendizaje Automático (AA) = Machine Learning (ML)


- Aprendizaje Automático
 - Enfocado en la técnica
 - Aprender un Modelo en base a Datos
- Minería de Datos
 - Enfocado en el conocimiento
 - Usa herramientas de AA

Minería de Datos

usa

Aprendizaje Automático

Tipos de Modelos





Modelos

predictivos/supervisados

Regresión

Permiten predecir

- El valor de un jugador en base a sus aptitudes
- Una aptitud de un jugador en base a las otras
- La posición de una cara en una foto
- El precio de un auto en base a sus atributos
- El año de una canción en base a sus tonos

Datos de entrada

Nominal

Continuo

Datos de Salida

Continuo

Modelos



Regresión
Lineal

Árboles de
Regresión


Redes
Neuronales

Regresión Lineal

Predicción del peso en base a la altura



Regresión Lineal Múltiple



Clasificación

Permiten predecir:

- La posición de un jugador en base a sus aptitudes
- El pie preferido de un jugador en base a sus aptitudes
- La persona a la que pertenece una cara en una foto
- La marca de un auto en base a sus atributos
- El género de una canción en base a sus tonos
- Spam

Datos de entrada

Nominal

Continuo

Datos de Salida

Nominal

Modelos

Regresión
Logística

Árboles de
Clasificación

Reglas de
Clasificación

¿Cómo los clasificarías?



¿Cómo los clasificarías?



Elementos básicos de una clasificación


- Identificar las características relevantes de cada tipo de elemento.
- Codificarlas como atributos y generar un conjunto de datos




Clasificación

- Objetivo

- Determinar las áreas del espacio de atributos de cada clase




Regresión Logística



Regresión Logística



Clasificación de frutas en base al color y el diámetro



	Diametro	Color	Clase
1	10.0	200.0	Naranja
2	23.0	170.0	Melon
3	8.0	150.0	Naranja
4	26.0	30.0	Melon
5	7.0	170.0	Naranja
6	24.0	32.0	Melon
7	20.0	170.0	Naranja
8	21.0	160.0	Melon
9	21.0	180.0	Naranja
10	23.0	160.0	Melon
11	22.0	190.0	Naranja
12	23.0	190.0	Melon
13	24.0	250.0	Naranja
14	15.0	31.0	Melon
15	15.0	250.0	Naranja
16	19.0	31.0	Melon
17	7.0	100.0	Naranja
18	23.0	180.0	Melon
19	25.0	70.0	Melon
20	10.0	210.0	Naranja
21	21.0	190.0	Naranja
22	22.0	180.0	Melon


Regresión Logística

Clasificación de frutas en base al color y el diámetro




Árboles de Clasificación

Clasificación de frutas en base al color y el diámetro



Árboles de Clasificación


Clasificación de pie preferido del jugador




Reglas de Clasificación

Clasificación de frutas en base al color y el diámetro

	IF conditions	THEN class	Distribution
0	Color $\geq$ 100.0 AND Color $\geq$ 200.0	→ Clase=Naranja	[0, 4]
1	Diametro $\geq$ 23.0	→ Clase=Melon	[7, 0]
2	Color $\geq$ 100.0 AND Diametro $\leq$ 21.0 AND Color $\geq$ 170.0	→ Clase=Naranja	[0, 4]
3	Diametro $\geq$ 15.0	→ Clase=Melon	[4, 1]
4	TRUE	→ Clase=Naranja	[11, 11]



Modelos descriptivos/no supervisados



Asociación

Permiten asociar:

- Qué items suelen comprar juntos los clientes
- Qué canciones se suelen escuchar después de otras
- Qué niveles de aptitud suele tener juntos un jugador

Datos de entrada

Nominal
Binario

Datos de Salida

Modelo

Modelos

Reglas de
Asociación

Reglas de Asociación

Items que se llevan de forma conjunta

Compra	Leche	Café	Te	Galletitas
1	Si	No	Si	No
2	No	Si	No	Si
3	Si	No	Si	Si
4	No	Si	No	No
5	No	No	Si	Si

Reglas de Asociación

Items que se llevan de forma conjunta

	Supp	Conf	Covr	Strg	Lift	Levr	Antecedent	Consequent
salad dressing toppings=1 → candy chocolate=1	.70	0.01	31.41	2.74	0.00		tropical fruit, yogurt, root vegetables →	whole milk
crackers=1 → candy chocolate=1	.70	0.00	125.65	2.74	0.00		yogurt, other vegetables, bottled water, root vegetables →	whole milk
chips pretzels=1 → candy chocolate=1	.75	0.00	209.42	2.94	0.00		yogurt, rolls/buns, bottled water, root vegetables →	whole milk
ice cream ice=1 → candy chocolate=1	.75	0.00	314.12	2.94	0.00		yogurt, other vegetables, rolls/buns, bottled water, root vegetables →	whole milk
salad dressing toppings=1 → packaged cheese=1	.77	0.00	146.38	3.98	0.00		yogurt, rolls/buns, soda, root vegetables →	other vegetables
ice cream ice=1 → packaged cheese=1	.70	0.00	103.20	6.67	0.00		yogurt, whole milk, other vegetables, rolls/buns, bottled water →	tropical fruit
chips pretzels=1 → packaged cheese=1	.88	0.00	171.50	6.27	0.00		tropical fruit, whole milk, other vegetables, rolls/buns, bottled water →	yogurt
candy chocolate=1 → salad dressing toppings=1	.70	0.00	251.30	2.74	0.00		tropical fruit, yogurt, other vegetables, rolls/buns, bottled water →	whole milk
missing=1 → candy chocolate=1	.70	0.00	190.30	3.62	0.00		tropical fruit, yogurt, whole milk, rolls/buns, soda →	other vegetables
packaged cheese=1 → candy chocolate=1	.77	0.00	105.54	5.51	0.00		tropical fruit, rolls/buns, bottled water, soda →	yogurt
ice cream ice=1 → salad dressing toppings=1	.83	0.00	228.67	5.97	0.00		tropical fruit, other vegetables, rolls/buns, bottled water, soda →	yogurt
packaged cheese=1 → salad dressing toppings=1	.71	0.00	51.29	2.80	0.00		tropical fruit, yogurt, other vegetables, root vegetables →	whole milk
ice cream ice=1 → packaged cheese=1	.81	0.00	93.07	3.19	0.00		tropical fruit, yogurt, rolls/buns, root vegetables →	whole milk
salad dressing toppings=1 → ice cream ice=1	.72	0.00	139.61	2.83	0.00		tropical fruit, yogurt, other vegetables, rolls/buns, root vegetables →	whole milk
candy chocolate=1 → ice cream ice=1	.70	0.00	51.60	6.67	0.00		yogurt, other vegetables, bottled water, root vegetables →	tropical fruit
chips pretzels=1 → ice cream ice=1	.79	0.00	73.71	7.49	0.00		yogurt, whole milk, other vegetables, bottled water, root vegetables →	tropical fruit
packaged cheese=1 → ice cream ice=1	.79	0.00	179.50	3.08	0.00		tropical fruit, yogurt, other vegetables, bottled water, root vegetables →	whole milk
ice cream ice=1 → packaged cheese=1	.73	0.00	126.87	3.79	0.00		tropical fruit, yogurt, whole milk, bottled water, root vegetables →	other vegetables
salad dressing toppings=1 → chips pretzels=1	.92	0.00	209.42	3.59	0.00		tropical fruit, rolls/buns, bottled water, root vegetables →	whole milk
chips pretzels=1 → chips pretzels=1	.89	0.00	114.67	8.47	0.00		yogurt, whole milk, rolls/buns, bottled water, root vegetables →	tropical fruit
ice cream ice=1 → chips pretzels=1	.73	0.00	124.73	5.21	0.00		tropical fruit, whole milk, rolls/buns, bottled water, root vegetables →	yogurt
packaged cheese=1 → chips pretzels=1	.00	0.00	314.12	3.91	0.00		tropical fruit, yogurt, rolls/buns, bottled water, root vegetables →	whole milk
candy chocolate=1 → chips pretzels=1	.83	0.00	228.67	5.97	0.00		tropical fruit, other vegetables, rolls/buns, bottled water, root vegetables →	yogurt
ice cream ice=1 → chips pretzels=1	.83	0.00	418.83	3.26	0.00		tropical fruit, other vegetables, rolls/buns, bottled water, root vegetables →	whole milk
packaged cheese=1 → chips pretzels=1	.83	0.00	172.00	7.94	0.00		yogurt, whole milk, other vegetables, rolls/buns, bottled water, root vegetables →	tropical fruit
candy chocolate=1 → crackers=1	.00	0.00	274.40	7.17	0.00		tropical fruit, whole milk, other vegetables, rolls/buns, bottled water, root vegetables →	yogurt
missing=1 → candy chocolate=1	.00	0.00	502.60	3.91	0.00		tropical fruit, yogurt, other vegetables, rolls/buns, bottled water, root vegetables →	whole milk
crackers=1 → candy chocolate=1	.83	0.00	91.83	14.87	0.00		tropical fruit, other vegetables, rolls/buns, bottled water, root vegetables →	yogurt, whole milk
ice cream ice=1 → candy chocolate=1	.71	0.00	153.14	6.55	0.00		tropical fruit, yogurt, whole milk, other vegetables, rolls/buns, bottled water →	root vegetables
chips pretzels=1 → candy chocolate=1	.75	0.00	158.58	3.88	0.00		tropical fruit, rolls/buns, soda, root vegetables →	other vegetables

Reglas de Asociación

Películas que ve una persona

Persona	Garage Olimpo	El Juego de la Silla	Hombre mirando..	Nueve Reinas
Juana	Si	No	Si	No
Juan	No	Si	No	Si
Martina	Si	No	Si	Si
Martín	No	Si	No	No
María	No	No	Si	Si

Agrupamiento

Permiten agrupar:

- Características de jugadores
 - Los arquetipos de las posiciones surgen naturalmente
- Qué canciones se suelen escuchar juntas
 - Géneros basados en datos
- Países
 - ¿Existe el “tercer mundo”?
- Transacciones de banco, para encontrar anómalas
- Fotos parecidas
- Videos

Datos de entrada

Discreto

Continuo

Datos de Salida

Modelo

Modelos



K-medias

SOM

Expectation
Maximization



Agrupamiento con K-Medias

Datos 2D sintéticos



Agrupamiento con K-Medias

Conexiones a una red



Agrupamiento con K-Medias

Animales (16 atributos)

animal	Tiene_Pelo	Tiene_Plumas	lace_de_huev	Toma_Leche	Vuela	Acuático
1 oso_hormi...	1	0	0	1	0	0
2 antilope	1	0	0	1	0	0
3 robalo	0	0	1	0	0	1
4 oso	1	0	0	1	0	0
5 jabali	1	0	0	1	0	0
6 bufalo	1	0	0	1	0	0
7 becerro	1	0	0	1	0	0
8 carpa	0	0	1	0	0	1
9 pez_gato	0	0	1	0	0	1
10 conejillo_d...	1	0	0	1	0	0
11 chita	1	0	0	1	0	0
12 gallina	0	1	1	0	1	0
13 coto	0	0	1	0	0	1
14 almeja	0	0	1	0	0	0
15 cangrejo	0	0	1	0	0	1
16 langostino	0	0	1	0	0	1
17 cuervo	0	1	1	0	1	0
18 ciervo	1	0	0	1	0	0
19 perro_mari...	0	0	1	0	0	1
20 delfin	0	0	0	1	0	1
21 paloma	0	1	1	0	1	0
22 pato	0	1	1	0	1	1
23 elefante	1	0	0	1	0	0
24 flamenco	0	1	1	0	1	0
25 pulga	0	0	1	0	0	0
26 rana	0	0	1	0	0	1

animal	Cluster	Silhouette	Tiene_Pelo	Tiene_Plumas	lace_de_huev	Toma_Leche
1 oso_hormi...	C1	0.617642	1	0	0	1
2 antilope	C1	0.657015	1	0	0	1
3 robalo	C5	0.661593	0	0	1	0
4 oso	C1	0.617642	1	0	0	1
5 jabali	C1	0.660031	1	0	0	1
6 bufalo	C1	0.657015	1	0	0	1
7 becerro	C1	0.632698	1	0	0	1
8 carpa	C5	0.596402	0	0	1	0
9 pez_gato	C5	0.661593	0	0	1	0
10 conejillo_d...	C1	0.586307	1	0	0	1
11 chita	C1	0.660031	1	0	0	1
12 gallina	C4	0.627624	0	1	1	0
13 coto	C5	0.661593	0	0	1	0
14 almeja	C2	0.549553	0	0	1	0
15 cangrejo	C2	0.57794	0	0	1	0
16 langostino	C2	0.585912	0	0	1	0
17 cuervo	C4	0.642782	0	1	1	0
18 ciervo	C1	0.657015	1	0	0	1
19 perro_mari...	C5	0.649525	0	0	1	0
20 delfin	C5	0.538889	0	0	0	1
21 paloma	C4	0.627624	0	1	1	0
22 pato	C4	0.633183	0	1	1	0
23 elefante	C1	0.657015	1	0	0	1
24 flamenco	C4	0.63955	0	1	1	0

Redes Neuronales

- Modelo genérico
 - Grafo de computación
 - Nodos *derivables*
 - Red derivable
 - Modular
 - Composición de subgrafos
 - Transforma vectores
 - Permite aprovechar grandes cantidades de datos



Clasificación


Regresión

Agrupamiento

Asociación

Más modelos


scikit-learn
algorithm cheat-sheet



Más modelos

lib C++ Library

Machine Learning Guide



Módulo 1: Inteligencia Artificial

Aspectos Éticos, Sociales
y Profesionales Avanzados
de Informática




Docentes

- **Lic. Santiago A. Ponte Ahón**
 - Aprendizaje Automático
 - Visión por Computadora
 - Datos Astronómicos
- **[Grabaciones] Dr. Facundo Quiroga**
 - Aprendizaje Automático
 - Visión por Computadora
 - Interpretabilidad de modelos



Ejes

- **Inteligencia artificial**
 - Introducción al tema
 - Tipos de modelos
 - Redes Neuronales
- **Evaluación de modelos**
 - En términos de desempeño
 - Para una tarea
 - Interpretabilidad
 - Sesgo
 - Interacción con el mundo
 - Problemas y soluciones



Clases y examen

- Clase 1: Introducción
- Clases 2, 3 y 4: Redes Neuronales
- Clases 5 y 6: Evaluación de Modelos. Interpretabilidad
- Clase 7: Examen
 - ≥ 4 aprobado, ≥ 6 promoción
- Actividades
 - Formularios para cada clase
 - Se discuten en clase, no cuentan para aprobación

Plataforma

<https://asignaturas.info.unlp.edu.ar/>

Aspectos Éticos, Sociales y Profesionales Avanzados de Informática - 2026

Curso

Configuración

Participantes

Calificaciones

Informes

Más ▾

▾ Bienvenida y presentación ✎

Colapsar todo ⋮

Les damos la bienvenida al aula virtual de la materia Aspectos ético, sociales y Profesionales Avanzados.

Es un gusto recibirles, esperamos poder trabajar con ustedes, conceptos actuales que proponen a la ética como aporte para pensar la relación entre informática, sociedad y cultura.

Nos interesa construir con ustedes, una mirada analítica que reconozca las especificidades la formación informática con un fuerte anclaje en los problemas sociales contemporáneos.

Para el desarrollo de las clases les habilitaremos en esta aula virtual, materiales y actividades.



Bibliografía

- Básica
 - Deep Learning with Python - F. Chollet
 - Deep Learning - I. Goodfellow
 - Artificial Intelligence: A Guide for Thinking Humans - Melanie Mitchell
- Recomendada
 - [Interpretable Machine Learning](#) - Christoph Molnar
 - Gödel, Escher, Bach - Douglas Hofstadter