


Clasificación binaria y predicción de probabilidades

Predicción de probabilidad de aprobar


- Entrada
 - Horas estudiadas
- Salida
 - Probabilidad de aprobar
- Datos de probabilidades
 - No son comunes



Horas	P(aprobar)
2	0.1
5	0.32
7	0.45
9	0.6
10	0.4
11	0.45
13.4	0.55
14	0.3
15	0.5

Clasificación en aprobado/desaprobado

- Entrada
 - Horas estudiadas
- Salida
 - 1: Aprobado
 - 0: Desaprobado
- Datos de aprobado/desaprobado
 - Fáciles de obtener







Horas	Aprobado
2	0
5	0
7	0
9	0
10	0
11	0
13.4	1
14	0
15	1

Convertir probabilidades en clases


- Umbral u
 - Método más común
 - u : valor entre 0 y 1
- Si $p(\text{aprobar}) > u$
 - Aprobado
- Sino
 - Desaprobado

Horas	P(aprobar)	u=0.35	Horas	Aprobado
2	0.1		2	0
5	0.32		5	0
7	0.45		7	1
9	0.6		9	1
10	0.4		10	1
11	0.45		11	1
13.4	0.55		13.4	1
14	0.3		14	0
15	0.5		15	1

Horas	P(aprobar)	u=0.5	Horas	Aprobado
2	0.1		2	0
5	0.32		5	0
7	0.45		7	0
9	0.6		9	1
10	0.4		10	0
11	0.45		11	0
13.4	0.55		13.4	1
14	0.3		14	0
15	0.5		15	1

Convertir clases en probabilidades

- 0 codifica desaprobado
- 1 codifica aprobado
 - Ya son probabilidades!




Horas	Aprobado
2	0
5	0
7	0
9	1
10	0
11	0
13.4	1
14	0
15	1

Horas	P(aprobar)
2	0
5	0
7	0
9	1
10	0
11	0
13.4	1
14	0
15	1

Predecir $p(\text{aprobar})$ vs clasificar aprobado/desap

- **Problemas distintos**
- Clasificación
 - 0 o 1
 - No hay intermedios
 - Caso especial de probabilidad
- Probabilidad
 - Valores entre 0 y 1
 - Más detalle
- Pero **relacionados**
 - Mismo modelo

Horas	P(aprobar)
2	0.1
5	0.32
7	0.45
9	0.6
10	0.4
11	0.45
13.4	0.55
14	0.3
15	0.5





Horas	Aprobado
2	0
5	0
7	0
9	0
10	0
11	0
13.4	1
14	0
15	1

Modelo para probabilidades/clases

- **Entrenar**

- Datos 0/1
 - Más comunes
 - Pueden considerarse probabilidades

Horas	Aprobado
2	0
5	0
7	0
9	0
10	0
11	0
13.4	1
14	0
15	1



Modelo para probabilidades/clases

- **Predecir**

- Genera probabilidades
- Opcional: convertir a clases
 - Umbral
 - $u=0.5$ lo más común

Salida modelo

Horas	P(aprobar)
2	0.1
5	0.32
7	0.45
9	0.6
10	0.4
11	0.45
13.4	0.55
14	0.3
15	0.5

u


Opcional

Horas	Aprobado
2	0
5	0
7	0
9	0
10	0
11	0
13.4	1
14	0
15	1

Resumen

- Entrada
 - Horas estudiadas
- Salida
 - Probabilidad de aprobar
- Entrenado con
 - Datos de aprobado/desaprobado
 - Interpretados como probabilidades

Horas	Aprobado
2	0
5	0
7	0
9	0
10	0
11	0
13.4	1
14	0
15	1




Horas	P(aprobar)
2	0.1
5	0.32
7	0.45
9	0.6
10	0.4
11	0.45
13.4	0.55
14	0.3
15	0.5

Regresión Logística - Modelo


Predicción de probabilidad de aprobar

- Entrada
 - Horas estudiadas
- Salida
 - Probabilidad de aprobar
- Entrenar
 - Datos de aprobado/desaprobado




Horas	Aprobado
2	0
5	0
7	0
9	0
10	0
11	0
13.4	1
14	0
15	1

Sin Regresión Logística: Modelo simple if/else




- Ejemplo
 - $f(x) = 0$ si $x < 20$
 $= 1$ si $x \geq 20$
- En general
- $f(x) = 0$ si $x < V$
 $= 1$ si $x \geq V$
- Problemas
 - Discontinuo en $x=V$
 - No es derivable
 - Muy extremo
 - 0 o 1

Sin Regresión Logística: Regresión Lineal $y=mx+b$



- Problemas
 - Valores mayores a 1
 - Valores menores a 0
- Solución
 - Convertir la salida de regresión lineal
 - Rango deseado
 - 0 a 1
 - Varias opciones


Sin Regresión Logística: Regresión Lineal cortada




- $f(x) = 0$ **si** $x \leq 10$
 $= mx + b$ **si** $10 < x < 35$
 $= 1$ **si** $x \geq 35$
- Soluciona el rango
- Problemas
 - No es derivable en $x=10$ y $x=35$
 - Difícil de optimizar

Regresión Logística


Regresión Logística = Regresión Lineal + Función Logística



+




=




Función Logística o Sigmoide $\sigma(x)$

- $\sigma(x) = 1 / (1 + e^{-x})$
- Dominio
 - $-\infty$ a $+\infty$
- Imagen
 - 0 a 1
 - Asíntotas horizontales
- Derivada simple
 - $\delta\sigma(z)/\delta z = \sigma(z) * (1 - \sigma(z))$
- Aplicar a la salida de la Regresión Lineal




Entendiendo la Función Logística o Sigmoides $\sigma(x)$

- e^x transforma valores de $(-\infty, +\infty)$ a valores $(0, \infty)$
 - $-\infty$ se convierte en 0
 - ∞ queda igual
- e^{-x} hace lo parecido, invirtiendo el signo:
 - $+\infty$ se convierte en 0
 - $-\infty$ se convierte en $+\infty$



- e^{-x} transforma valores de $(-\infty, +\infty)$ a valores $(0, \infty)$
 - $+\infty$ se convierte en 0
 - $-\infty$ se convierte en $+\infty$
- $1 + e^{-x}$
 - $+\infty$ se convierte en 1
 - $-\infty$ se convierte en $+\infty$



Entendiendo la Función Logística o Sigmoides $\sigma(x)$

- $1 + e^{-x}$


- $+\infty$ se convierte en 1

- $-\infty$ se convierte en $+\infty$

- $\frac{1}{1+e^{-x}}$

- $+\infty$ se convierte en 1


- $-\infty$ se convierte en 0



- $\sigma(x) = 1 / (1+e^{-x})$


- $f(x) = \sigma(mx+b)$
 $= 1 / (1+e^{-mx-b})$

- f = regresión lineal
compuesta con sigmoidea




$f(x) = 1 / (1 + e^{-(mx+b)})$: Salida en base a m ($b=-25$)


- m cambia la “pendiente” de la parte “lineal” de $\sigma(x) = 1/(1+e^{-x})$



- $m > 0$
- $m \sim 0$




- $m = 1$




- $m \gg 1$

$f(x) = 1 / (1 + e^{-(mx+b)})$: Salida en base a m (b=-25)


- m cambia la “pendiente” de la parte “lineal” de $\sigma(x) = 1/(1+e^{-x})$



- $m < 0$
- $m \sim 0$




- $m = -11$




- $m \ll -1$

$f(x) = 1 / (1 + e^{-(mx+b)})$: Salida en base a b (m=0)


- Cambiar b mueve el gráfico en el eje x



- $b=5$




- $b=0$




- $b=-5$

Simulación interactiva



Frontera de decisión 1D



- Asumimos un umbral $u=0.5$
- Si $w=0.3$ y $b=-4$
- Entonces
 - $y = 1$ si $f(x) > 0.5$
- $f(x) > u$
 $\sigma(mx+b) > 0.5$
 $mx+b > 0$
 $x > -b/m$ (si $m > 0$)
- $x > -(-4)/0.3$
 $x > \mathbf{13.3}$



Frontera de decisión 2D


- $f(x_1, x_2) = \sigma(w_1 x_1 + w_2 x_2 + b)$
- Ejemplo con
 - $w = [0.47, 0.05]$
 - $b = -8$

$$y = 1 \text{ si } g(x) > 0,5 \rightarrow w_1 x_1 + w_2 x_2 + b > 0$$
$$0,47x_1 + 0,05x_2 - 8 > 0$$
$$0,47x_1 + 0,05x_2 > 8$$
$$x_2 = 160 - 9,4x_1$$



Regresión Logística. Resumen.

- Modelo $f(x_1, x_2, \dots, x_m) = \sigma(x_1 w_1 + x_2 w_2 + \dots + x_m w_m + b)$
 - $\sigma(x) = 1/(1+e^{-x})$
 - Sigmoide o Logística
 - Convierte imagen a 0-1
 - $f(x) = \sigma(\text{RegresionLineal}(x))$
- Umbral
 - Convierte probabilidades a clases
 - Frontera de decisión
- w y b
 - Modifican la frontera



Función Logística o Sigmoides

1. Abrir el archivo **Funcion Logistica.ipynb**
2. Probar con algunos valores distintos de x para ver como cambia a cada paso la transformación.
3. ¿Para qué valor $\sigma(x) = 0.5$?
4. Dadas las asíntotas, sería teóricamente imposible que $\sigma(x)$ de como resultado 1 o 0. No obstante, en una computadora ¿podés hacer que, de todos modos, de como resultado 0 o 1? ¿por qué?

Modelo Regresión Logística

- Abrir el archivo **Separación por hiperplanos.ipynb**
 - ¿Qué valor tiene la salida de un lado y del otro del plano?
 - ¿Y el valor de $xw + b$?
 - Probar variando los valores de W y b
 - ¿Cómo varían las regiones?


Función de Error

Entropía Cruzada Binaria

Error cuadrático medio

- $E = 1/n \sum_i^n E_i$
- $E_i = (\sigma(mx_i + b) - y_i)^2$
- Funciona, pero
 - E es ECM de $\sigma(mx + b)$
 - E no es convexa
- Podemos definir otro E que sea convexa
 - **Entropía Cruzada**
 - Función de error
 - Convexa para $\sigma(mx_i + b)$

ECM de $\sigma(mx+b)$



Entropía Cruzada Binaria

- $E = 1/n \sum_i^n E_i$

- $E_i =$

- $-\log(\sigma(mx_i+b))$ si $y_i=1$


- $-\log(1-\sigma(mx_i+b))$ si $y_i=0$

- $E_i =$

- $-\log(f(x_i))$ si $y_i=1$


- $-\log(1-f(x_i))$ si $y_i=0$

Si $y = 1$ & $f(x)=0$
→ error = ∞



Si $y = 1$ & $f(x)=1$ →
error = 0

Si $y_i=0$



Si $y = 0$ & $f(x)=0$ →
error = 0



Si $y = 0$ & $f(x)=1$
→ error = ∞

$f(x) = \sigma(mx_i+b)$ es un valor entre 0 y 1 → entrada a $\log(x)$

Entropía Cruzada Binaria - Fórmula vectorial

- $E_i =$
 - $-\log(f(x_i))$ si $y_i=1$
 - $-\log(1-f(x_i))$ si $y_i=0$
- Podemos escribir E_i como
 - $E_i = y_i [-\log(f(x_i))] + (1-y_i) [-\log(1-f(x_i))]$
 - Ejemplo
 - $y_i=1$
 - $y_i [-\log(f(x_i))] + (1-y_i) [-\log(1-f(x_i))]$
 $= 1 [-\log(f(x_i))] + 0 [-\log(1-f(x_i))]$
 $= [-\log(f(x_i))]$
- y_i actúa como función indicadora
 - Si $y_i=1$, contribuye $[-\log(f(x_i))]$
 - Si $y_i=0$, contribuye 0
- Idem $1-y_i$ al revés

Entropía Cruzada



Interpretación de entropía cruzada Binaria

- Distancia entre distribuciones
 - $f(x) = 0.3$
 - $P(x \text{ es de clase} = 1) = 0.3$
 - $P(x \text{ es de clase} = 0) = 1 - P(x \text{ es de clase} = 1)$
 $= 1 - 0.3 = 0.7$
 - $P(x \text{ es de clase} = 1)$ y $P(x \text{ es de clase} = 0)$ forman una **distribución de probabilidad**
- ECM
 - Mide distancia entre **puntos**
 - Distancia **euclídea al cuadrado**
- Entropía Cruzada
 - Mide distancia entre **distribuciones de probabilidad**
 - Distancia **Kullback-Leibler** (o Divergencia)


Distancia entre distribuciones

- Sean p y q distribuciones sobre n valores
 - p_i y q_i = probabilidad de tomar el valor i
 - $\text{KullbackLeibler}(p,q) = \sum_i^n p_i \log(q_i/p_i)$
- $\text{KullbackLeibler}(B,C)$
= $\text{KullbackLeibler}((0,1), (1,0))$
= $B_1 \log(C_1/B_1) + B_2 \log(C_2/B_2)$
= $0^1 \infty + 1^1 \infty = \infty$
 - Peor caso
- $\text{KullbackLeiber}(C,A)$
= $\text{KullbackLeiber}((1,0),(0.3,0.7))$
= $1 \log(0.3/1) + 0 \log(0.7/0) = \log(0.3)$
- $\text{KullbackLeiber}(A,C)$
= $\text{KullbackLeiber}((0.3,0.7), (1,0))$
= $0.3 \log(1/0.3) + 0.7 \log(0/0.7) = \dots$

Distribución	1	2
A	0.3	0.7
B	0.0	1.0
C	1.0	0.0

Derivadas de Entropía Cruzada Binaria

- $\delta E(m,b)/\delta b = 1/n \sum_i^n y_i - f(x_i)$
- $\delta E(m,b)/\delta m = 1/n \sum_i^n (y_i - f(x_i)) x_i$
 - Son iguales que las de Regresión Lineal!
 - [**ojo**: $f(x) = \sigma(mx+b)$]
- Mismas ecuaciones de Descenso de Gradiente
 - $b = b - \alpha 1/n \sum_i^n (y_i - f(x_i))$
 - $m = m - \alpha 1/n \sum_i^n (y_i - f(x_i)) x_i$



Accuracy: Métrica de clasificación

- Valores de entropía cruzada: 0 a $+\infty$
 - Difíciles de interpretar
- Accuracy = % de ejemplos que clasificó correctamente

Aprobado	Predicción	Acierto
0	0	1
1	1	1
1	0	0
0	1	0
0	0	1
0	0	1
1	0	0
0	1	0

- **Acierto**
 - 1 si Aprobado = Predicción
- **Accuracy**
 - Promedio de columna **Acierto**
- Ejemplo
 - $N = 8$
 - aciertos=4
 - Accuracy = aciertos/ N
 - $= 4/8 = 0.5$
 - Accuracy(%) = 50%

Resumen

- **Error Cuadrático Medio**
 - No es convexo
 - Respecto de $\sigma(mx+b)$
- **Entropía Cruzada Binaria**
 - Es convexa
 - Derivadas simples
 - E iguales a Regresión Lineal + ECM
 - Difícil de interpretar
 - Accuracy: *métrica* de clasificación
- 2 o m variables de entrada?
 - No lo vimos
 - Generalización similar a la de Regresión Lineal
 - Mismos resultados


Regresión Logística - Notebooks

- Abrir el archivo **Regresion Logistica - Modelo.ipynb**
 - Modificar los parámetros, observar cómo cambia la función de predicción y el error.
- Abrir el archivo **Regresion Logística - Aprendizaje.ipynb**
 - Experimentar con los valores iniciales de los parámetros, así como los hiperparámetros α y el número de iteraciones
- Idem versiones 2D de los cuadernos

Regresión Logística con Múltiples Variables de Salida

Regresión Logística (dos clases)

Estudio	Edad	Promedio	Aprobó (y)
2	24	4	0
5	22	3	1
7	25	4	0
9	20	7	1
10	19	4	0
11	20	3	0
13,4	21	5	1
14	20	3	0



¿Si hay N clases?

$$s(x) = 1 / (1 + \exp(-x))$$

```
def sigmoide(x):  
    d = 1 + np.exp(-x)  
    return 1/d
```

Probabilidad de aprobar.
Si > 0.5 ,
clasificar como
"aprobado"

Regresión Logística Múltiple

Múltiples opciones
=> predicciones independientes

Variables (x)			Carrera (y)		
Estudio	Edad	Promedio	P1	P2	P3
2	24	4	0	1	1
5	22	3	1	1	1
7	25	4	0	1	0
9	20	7	1	0	1
10	19	4	0	1	0
11	20	3	1	1	1
13,4	21	5	1	0	1
14	20	3	0	1	0

Clases mutuamente exclusivas
=> Problema de **clasificación**

Variables (x)			Carrera (y)		
Estudio	Edad	Promedio	LS	LI	IC
2	24	4	1	0	0
5	22	3	0	1	0
7	25	4	0	1	0
9	20	7	0	0	1
10	19	4	0	0	0
11	20	3	0	0	1
13,4	21	5	0	1	0
14	20	3	1	0	0


En esta materia:
**problemas de
clasificación**

Regresión Logística Múltiple - Intuición

Un hiperplano por cada clase



Dividen el espacio en regiones por clase



Regresión Logística Múltiple - Codificación

Codificación “One Hot”. Cada clase con su columna. Tamaño de y : $N \times C$


Variables (x)			Carrera (y)		
Estudio	Edad	Promedio	LS	LI	IC
2	24	4	1	0	0
5	22	3	0	1	0
7	25	4	0	1	0
9	20	7	0	0	1
10	19	4	1	0	0
11	20	3	0	0	1
13,4	21	5	0	1	0
14	20	3	1	0	0

Codificación con etiquetas. Cada clase con su ID. Tamaño de y : $N \times 1$

Variables (x)			Carrera (y)
Estudio	Edad	Promedio	LS = 0, LI = 1, IC = 2
2	24	4	0
5	22	3	1
7	25	4	1
9	20	7	2
10	19	4	0
11	20	3	2
13,4	21	5	1
14	20	3	0

Softmax

- Similar a **Regresión Lineal** pero para predecir probabilidades
- Función **softmax** aplicada a la salida
 - Genera **distribución de probabilidad $P(y)$**
- **Clasificación de N clases**



Softmax

- Función **softmax**
 - Convierte salida de Regresión Lineal en distribución de probabilidades de c/ clase

¿Por qué e^x ?

- Resultado > 0
- Exponencial, acentúa los valores altos
- Podría ser con otra base

Y:

[4, 8, 3]

Softmax

1) Cálculo del vector E

$$E = [e^4, e^8, e^3] = [54.59, 2980.95, 20.08]$$

2) Cálculo del valor N

$$N = e^4 + e^8 + e^3 = 54.59 + 2980.95 + 20.08 = 3055.63$$

3) Cálculo del vector P de probabilidades

$$\begin{aligned} P &= E / N = [e^4/N, e^8/N, e^3/N] \\ &= [54.59/3055.63, 2980.95/3055.63, 20.08/3055.63] \end{aligned}$$

P:

[0.018, 0.975,
0.007]

Softmax

Y:

[4, 8, 3]


```
def softmax(Y):  
    n=len(Y)  
    E=np.zeros_like(Y)  
    for i in range(n):  
        E[i] = np.exp(Y[i])  
    N=0  
    for i in range(n):  
        N=N+E[i]  
    P=np.zeros_like(Y)  
    for i in range(n):  
        P[i]=E[i]/N  
    return P
```

P:

[0.018, 0.975,
0.007]

Versión vectorial:
def softmax(Y):
 E=np.exp(Y)
 N=np.sum(E)
 return E/N

Función de error: Entropía Cruzada




- Cambia la función de salida
 - Cambia la función de error
- Salida: Softmax
 - Error: Entropía Cruzada
- Penaliza la salida de la clase verdadera:
 - $-\ln(P[\text{clase_verdadera}])$

Repaso Logaritmo

- Funciones $\ln(x)$ y $-\ln(x)$
 - Cuando $0 \leq x \leq 1$
- Si x tiende a 1
 - $\ln(x)$ tiende a 0
 - $-\ln(x)$ tiende a 0
- Si x tiende a 0
 - $\ln(x)$ tiende a $-\infty$
 - $-\ln(x)$ tiende a $+\infty$

Entonces


- $-\ln(P[\text{clase_verdadera}])$
 - Penaliza si $P[\text{clase_verdadera}] = 0$
 - NO penaliza si $P[\text{clase_verdadera}] = 1$



Función de error - Entropía Cruzada

Función de error = Entropía Cruzada = $-\ln(P[\text{clase_verdadera}])$

Variables			Carrera	xW+b			P(Carrera)			E	
Estudio	Edad	Promedio	LS = 0, LI = 1, IC = 2	LS	LI	IC	LS	LI	IC		
2	24	4	0	46	50	50.2	0.01	0.45	0.55	$-\log(0.01)$	4.61
14	20	3	0	69	66	66.1	0.91	0.05	0.05	$-\log(0.91)$	0.09



- $-\ln(P[\text{clase_verdadera}])$
 - Penaliza mucho si $P[\text{clase_verdadera}] \sim 0$
 - Penaliza poco si $P[\text{clase_verdadera}] \sim 1$


Función de error - Entropía Cruzada

Función de error = Entropía Cruzada Promedio = E.mean()

Variables			Carrera	xW+b			P(Carrera)			E	
Estudio	Edad	Promedio	LS = 0, LI = 1, IC = 2	LS	LI	IC	LS	LI	IC		
2	24	4	0	46	50	50.2	0.01	0.45	0.55	-log(0.01)	4.61
5	22	3	1	49.5	51	51.3	0.09	0.39	0.52	-log(0.39)	0.94
7	25	4	1	60	61.5	61.8	0.09	0.39	0.52	-log(0.39)	1.20
9	20	7	2	60.5	64	62.9	0.02	0.73	0.24	-log(0.24)	1.43
10	19	4	0	58.5	58.5	58.2	0.36	0.36	0.27	-log(0.36)	1.35
11	20	3	2	61.5	60	60.1	0.68	0.15	0.17	-log(0.17)	0.39
13,4	21	5	1	71	70.3	69.9	0.55	0.27	0.18	-log(0.55)	1.31
14	20	3	0	69	66	66.1	0.91	0.05	0.05	-log(0.91)	0.09

Error Promedio = 1.41

Función de error - Entropía Cruzada



Y	P		
LS = 0, LI = 1, IC = 2	LS	LI	IC
0	0.01	0.45	0.55
1	0.09	0.39	0.52
1	0.09	0.39	0.52
2	0.02	0.73	0.24
0	0.36	0.36	0.27
2	0.68	0.15	0.17
1	0.55	0.27	0.18
0	0.91	0.05	0.05

```
def entropia_promedio(P, Y):  
    n = len(Y)  
    es = np.zeros(n)  
    for i in range(n):  
        p = P[i, :]  
        y = Y[i]  
        es[i] = entropia_ejemplo(p, y)  
    return es.mean()
```

Promedio = 1.41

Keras - Con Codificación por Etiquetas

```
x,y=cargar_dataset(one_hot=False)
nx,d_in = x.shape # x tiene tamaño n x d_in
ny = y.shape # y tiene tamaño n x 1 (codificación etiquetas)
classes=y.max()+1 # etiqueta de clase máxima+1
assert(nx=ny) # misma cantidad de ejemplos en ambos vectores
import keras
#Creamos el modelo
model=keras.Sequential()
#Capa lineal que convierte vector de d_in a d_out dims
model.add(keras.Dense(classes,input_shape=[d_in],
                      activation="softmax"))
model.compile(loss='sparse_categorical_crossentropy',# ent. cruz.
              optimizer='sgd') # descenso de gradiente
history = model.fit(x,y,epochs=100,batch_size=32)
y_predicted=model.predict(x)
```

Keras - Con Codificación One Hot

```
x,y=cargar_dataset(one_hot=True)
nx,d_in = x.shape # x tiene tamaño n x d_in
ny,classes = y.shape # y tiene tamaño n x clases (one hot)
assert(nx=ny) # misma cantidad de ejemplos en ambos vectores

import keras
#Creamos el modelo
model=keras.Sequential()
#Capa lineal que convierte vector de d_in a d_out dims
model.add(keras.Dense(classes,input_shape=[d_in],
                       activation="softmax"))
model.compile(loss='categorical_crossentropy',# ent. cruz.
              optimizer='sgd') # descenso de gradiente
history = model.fit(x,y,epochs=100,batch_size=32)
y_predicted=model.predict(x)
```

Accuracy con varias clases

- Accuracy = % de ejemplos que clasificó correctamente

Carrera	P(Carrera)			Predicción	Acierto
LS = 0, LI = 1, IC = 2	LS	LI	IC		
0	0.01	0.45	0.55	2	0
1	0.09	0.39	0.52	2	0
1	0.09	0.39	0.52	2	0
2	0.02	0.73	0.24	1	0
0	0.36	0.36	0.27	0	1
2	0.68	0.15	0.17	0	0
1	0.55	0.27	0.18	0	0
0	0.91	0.05	0.05	0	1

- **Predicción**
 - $P(\text{Carrera}).\text{argmax}()$
 - El índice del mayor elemento
- **Acierto**
 - 1 si Carrera = Predicción
- **Accuracy**
 - Promedio de columna **Acierto**
- Ejemplo
 - $N = 8$
 - aciertos=2
 - $\text{Accuracy} = \text{aciertos}/N = 2/8 = 0.25$
 - $\text{Accuracy}(\%) = 25\%$

Resumen

- Permite realizar clasificación de **más de 2 clases**
- Función **softmax** se aplica luego de la regresión lineal
 - Genera una distribución de probabilidades
- **Entropía cruzada:** error adecuado para la **softmax**
- Sigue teniendo una solución única (optimización convexa)

Variables			Carrera
Estudio	Edad	Promedio	LS = 0, LI = 1, IC = 2
2	24	4	0
5	22	3	1
7	25	4	1
9	20	7	2
10	19	4	0
11	20	3	2
13,4	21	5	1
14	20	3	0